

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH

BÁO CÁO NHIỆM VỤ NGHIÊN CỨU & BÀI TẬP LỚN
PHÂN LOẠI CẢM XÚC ĐÁNH GIÁ SẢN PHẨM
AMAZON DÙNG MÔ HÌNH HỌC MÁY VÀ XỬ LÝ
NGÔN NGỮ TỰ NHIÊN

BÀI 2: PHÂN TÍCH DỮ LIỆU VĂN BẢN VÀ MÔ HÌNH HỌC MÁY 3 LỚP TRÊN DỮ
LIỆU MẤT CÂN BẰNG TỐI CAO

Môn học:	Nền tảng lập trình cho phân tích và trực quan dữ liệu
Mã học phần:	CO2011 / CO2013 / CO2015
Học kỳ / Năm học:	Học kỳ 261 – Năm học 2026–2027
Giảng viên hướng dẫn:	PGS.TS. Lê Thành Sách
Ngành đào tạo:	Khoa học Dữ liệu / Kỹ thuật Máy tính / Khoa học Máy tính

TÓM TẮT BÁO CÁO (EXECUTIVE SUMMARY)

Báo cáo nghiên cứu thực nghiệm này trình bày chi tiết toàn bộ quy trình phân tích dữ liệu khám phá (EDA), tiền xử lý ngôn ngữ tự nhiên (NLP), và xây dựng mô hình học máy 3 lớp (Tiêu cực, Trung tính, Tích cực) nhằm phân loại cảm xúc từ dữ liệu đánh giá sản phẩm Amazon. Tập dữ liệu thực nghiệm bao gồm **4,915** bản ghi ban đầu, sau khi loại bỏ dữ liệu khuyết và trùng lặp còn **4,912** bản ghi hợp lệ. Thách thức cốt lõi của bài toán nằm ở **hiện tượng mất cân bằng nhãn cực kỳ nghiêm trọng** giữa lớp Tích cực (4,448 mẫu - 90.55%) và lớp Trung tính (140 mẫu - 2.85%), với tỷ lệ lệch nhãn lên tới **31.8 : 1**.

Nghiên cứu tiến hành so sánh đối sánh 5 mô hình phân loại: Dummy Classifier (Baseline), Multinomial Naive Bayes, Logistic Regression (Mặc định), LinearSVC (Balanced), và Logistic Regression (Tuned với tham số $C = 3.0$ kết hợp `class_weight='balanced'`). Để ngăn ngừa hiện tượng rò rỉ dữ liệu (Data Leakage), toàn bộ quy trình biến đổi TF-IDF và huấn luyện được đóng gói nghiêm ngặt trong Scikit-Learn Pipeline cùng chiến lược phân tách Stratified K-Fold. Kết quả cho thấy mô hình Logistic Regression Tuned đạt chỉ số **Macro F1-score = 0.593**, nâng khả năng nhận diện các khiếu nại Tiêu cực (Recall lớp 0) từ 27.1% lên **77.1%**. Đánh giá mở rộng trên tập dữ liệu ngoài miền (`external_test.jsonl` gồm **5,000** mẫu) cho thấy chỉ số Macro F1 sụt giảm xuống **0.389**, chỉ ra ranh giới hạn chế của phương pháp biểu diễn từ theo tần suất (TF-IDF/Bag-of-Words) trước sự dịch chuyển miền từ vựng (Domain Shift). Báo cáo đề xuất giải pháp kiến trúc nâng cấp hệ thống dựa trên mô hình Pre-trained Transformer (RoBERTa/DeBERTa) và kỹ thuật tái lấy mẫu SMOTE-NC.

Mục lục

Tóm tắt báo cáo	i
1 CHƯƠNG 1: TỔNG QUAN ĐỀ TÀI VÀ ĐẶT VẤN ĐỀ (CÂU HỎI 1)	1
1.1 1.1. Đặt vấn đề trong Thương mại Điện tử và Phân tích Cảm xúc	1
1.2 1.2. Phát biểu Toán học của Bài toán Phân loại 3 Lớp	1
1.3 1.3. Các Thách thức Kỹ thuật Cốt lõi	1
1.4 1.4. Mục tiêu Nghiên cứu và Cấu trúc Báo cáo	2
2 CHƯƠNG 2: CƠ SỞ LÝ THUYẾT VÀ PHƯƠNG PHÁP NGHIÊN CỨU (CÂU HỎI 1 & 3)	3
2.1 2.1. Quy trình Tiền xử lý Ngôn ngữ Tự nhiên	3
2.1.1 2.1.1. Chuẩn hóa Văn bản (Text Normalization)	3
2.1.2 2.1.2. Trích xuất Chuỗi Từ đi kèm (N-gram Extraction)	3
2.2 2.2. Biểu diễn Trọng số Văn bản TF-IDF (TfidfVectorizer)	3
2.2.1 2.2.1. Tần suất Từ (Term Frequency - TF)	3
2.2.2 2.2.2. Tần suất Văn bản Nghịch đảo (Inverse Document Frequency - IDF) .	3
2.2.3 2.2.3. Trọng số TF-IDF Tổng hợp	4
2.3 2.3. Ngăn ngừa Rò rỉ Dữ liệu (Data Leakage) bằng Scikit-Learn Pipeline	4
2.4 2.4. Toán học các Thuật toán Phân loại Thử nghiệm	4
2.4.1 2.4.1. Dummy Classifier (Baseline)	4
2.4.2 2.4.2. Multinomial Naive Bayes	5
2.4.3 2.4.3. Logistic Regression (Điều chỉnh Trọng số Lớp - Balanced)	5
2.4.4 2.4.4. Linear Support Vector Classifier (LinearSVC Balanced)	5
2.5 2.5. Báo cáo Đánh giá Mô hình (Classification Report Metrics)	5
3 CHƯƠNG 3: THỰC NGHIỆM KHÁM PHÁ VÀ TIỀN XỬ LÝ DỮ LIỆU (CÂU HỎI 2)	7
3.1 3.1. Quy trình Làm sạch và Chuẩn hóa Dữ liệu	7
3.2 3.2. Phân tích Hiện tượng Mất Cân Bằng Nhãn (Class Imbalance)	7
3.3 3.3. Phân tích Cấu trúc Độ dài Văn bản (Word Count Analysis)	7
3.4 3.4. Trích xuất Đặc trưng Từ vựng Phân biệt (Top TF-IDF Keywords/Bigrams) . . .	8
4 CHƯƠNG 4: QUY TRÌNH THỰC NGHIỆM VÀ CẤU HÌNH MÔ HÌNH (CÂU HỎI 3)	9
4.1 4.1. Kiến trúc Pipeline và Phân tách Dữ liệu	9
4.2 4.2. Cấu hình Tham số Chi tiết cho các Mô hình Thực nghiệm	9
5 CHƯƠNG 5: KẾT QUẢ THỰC NGHIỆM VÀ PHÂN TÍCH ĐÁNH GIÁ	10
5.1 5.1. So sánh Hiệu năng Tổng hợp trên Tập Kiểm thử Nội bộ (737 mẫu)	10
5.2 5.2. Báo cáo Phân loại Chi tiết (Classification Report) Mô hình Tối ưu	10
5.3 5.3. Phân tích Ma trận Nhầm lẫn và Các Trường hợp Sai số	10
5.4 5.4. Thực nghiệm Kiểm thử trên Tập Dữ liệu Mở rộng (External Test Set)	11
5.5 5.5. Phân tích Nguyên nhân Suy giảm Hiệu năng (Domain Shift Analysis)	11

6	CHƯƠNG 6: ĐỀ XUẤT KIẾN TRÚC VÀ NÂNG CẤP HỆ THỐNG	12
6.1	6.1. Ứng dụng Mô hình Ngôn ngữ Pre-trained Transformers (RoBERTa / DeBERTa)	12
6.2	6.2. Kỹ thuật Tái lấy mẫu và Loss Function Nâng cao	12
7	CHƯƠNG 7: KẾT LUẬN	13
	Tài liệu tham khảo	13

Danh sách bảng

1	Thống kê mô tả chi tiết phân bố nhãn cảm xúc trong bộ dữ liệu Amazon	7
2	Chỉ số thống kê mô tả cấu trúc độ dài văn bản (Word Count) theo từng lớp nhãn	8
3	Danh sách các đặc trưng từ vựng và cụm từ đi kèm có trọng số TF-IDF cao nhất	8
4	Ma trận cấu hình kỹ thuật và siêu tham số cho 5 mô hình phân loại	9
5	Bảng đối sánh hiệu năng chi tiết giữa các mô hình phân loại trên tập Test độc lập	10
6	Báo cáo chi tiết hiệu năng từng lớp của mô hình Logistic Regression Tuned . . .	10
7	Ma trận nhầm lẫn (Confusion Matrix) mô hình Logistic Regression Tuned	10
8	So sánh đối sánh hiệu năng giữa tập Test nội bộ và tập Test ngoài (External Test)	11

1. CHƯƠNG 1: TỔNG QUAN ĐỀ TÀI VÀ ĐẶT VẤN ĐỀ (CÂU HỎI 1)

1.1 1.1. Đặt vấn đề trong Thương mại Điện tử và Phân tích Cảm xúc

Trong kỷ nguyên số hóa thương mại điện tử (E-Commerce), trải nghiệm và phản hồi của người tiêu dùng đóng vai trò chiến lược đối với sự tồn tại của các nền tảng bán lẻ. Amazon xử lý hàng trăm triệu giao dịch và hàng triệu bài đánh giá (Customer Reviews) mỗi ngày. Những bài đánh giá này chứa đựng thông tin trực tiếp về chất lượng sản phẩm, độ tin cậy của người bán, cũng như các điểm nghẽn trong dịch vụ giao nhận.

Phân tích cảm xúc (Sentiment Analysis / Opinion Mining) là bài toán xử lý ngôn ngữ tự nhiên (NLP) nhằm trích xuất trạng thái thái độ, cảm xúc và đánh giá định tính của con người từ văn bản thô. Trong ngữ cảnh E-Commerce, chuyển đổi các bài đánh giá thô sang 3 nhóm nhãn tiêu chuẩn:

- **Tiêu cực (Negative - Label 0):** Đánh giá 1.0 đến 2.0 sao – Thể hiện sự thất vọng, hỏng hóc kỹ thuật, hoặc yêu cầu hoàn tiền.
- **Trung tính (Neutral - Label 1):** Đánh giá 3.0 sao – Thể hiện thái độ do dự, phân vân, hoặc sản phẩm tạm chấp nhận được so với giá tiền.
- **Tích cực (Positive - Label 2):** Đánh giá 4.0 đến 5.0 sao – Thể hiện sự hài lòng cao, khen ngợi chất lượng và khuyến nghị mua hàng.

Việc tự động hóa quy trình phân loại này giúp doanh nghiệp tự động phát hiện các khiếu nại nghiêm trọng để ưu tiên xử lý, đồng thời tổng hợp xu hướng hài lòng của khách hàng theo thời gian thực.

1.2 1.2. Phát biểu Toán học của Bài toán Phân loại 3 Lớp

Cho tập dữ liệu văn bản bài đánh giá $\mathcal{D} = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$, trong đó:

- $x_i \in \mathcal{X}$ là chuỗi ký tự văn bản đánh giá thô của bản ghi thứ i .
- $y_i \in \mathcal{Y} = \{0, 1, 2\}$ là nhãn cảm xúc tương ứng.

Mục tiêu của bài toán là tìm một hàm phân loại $\hat{f} : \mathcal{X} \rightarrow \mathcal{Y}$ sao cho giảm thiểu hàm mất mát tổng quát (Expected Loss) trên tập kiểm thử độc lập:

$$\hat{f} = \arg \min_{f \in \mathcal{F}} \mathbb{E}_{(x,y) \sim \mathcal{P}} [\mathcal{L}(f(x), y)] \quad (1)$$

Trong đó $\mathcal{P}(x, y)$ là phân phối xác suất đồng thời thực tế của dữ liệu văn bản và nhãn cảm xúc.

1.3 1.3. Các Thách thức Kỹ thuật Cốt lõi

Thực thi bài toán phân loại cảm xúc đánh giá Amazon đối mặt với 4 thách thức kỹ thuật lớn:

1. **Hiện tượng Mất cân bằng Nhãn Cực kỳ Nghiêm trọng (Extreme Class Imbalance):** Lớp Tích cực chiếm hơn 90% tổng số mẫu, khiến các mô hình học máy dễ bị chệch (biased) về lớp đa số để tối ưu hóa độ chính xác tổng thể (Accuracy).

2. **Sự Biến động Độ dài Văn bản (Text Length Heterogeneity):** Văn bản đánh giá bao gồm cả các câu cực kỳ ngắn ("*Good product*") lẫn các bài phân tích dài hàng nghìn từ trình bày chi tiết hòng học kỹ thuật.
3. **Sự Đa dạng Ngữ nghĩa và Sarcasm (Mỉa mai):** Sự xuất hiện của các từ khen ngợi nằm trong ngữ cảnh chê bai (ví dụ: "*Great job breaking my data after 2 days*").
4. **Sự Dịch chuyển Miền Từ vựng (Domain Shift):** Tập dữ liệu huấn luyện tập trung vào nhóm linh kiện / thẻ nhớ điện tử, trong khi tập kiểm thử mở rộng chứa sản phẩm thời trang và gia dụng.

1.4 1.4. Mục tiêu Nghiên cứu và Cấu trúc Báo cáo

Báo cáo này tập trung giải quyết 5 mục tiêu thực nghiệm cốt lõi:

- Thực hiện làm sạch, loại bỏ trùng lặp và phân tích EDA toàn diện cấu trúc bộ dữ liệu Amazon.
- Biểu diễn toán học kỹ thuật biến đổi vector văn bản TF-IDF và cơ chế ngăn ngừa rò rỉ dữ liệu bằng Scikit-Learn Pipeline.
- Huấn luyện và tinh chỉnh 5 thuật toán phân loại khác nhau, ứng dụng chiến lược điều chỉnh trọng số lớp (`class_weight='balanced'`).
- Phân tích đối sánh chuyên sâu hiệu năng mô hình qua Báo cáo Đánh giá (Classification Report) và Ma trận Nhầm lẫn (Confusion Matrix).
- Đánh giá khả năng tổng quát hóa trên tập kiểm thử ngoài miền (`external_test.jsonl`) và đề xuất kiến trúc cải tiến tiên tiến.

2. CHƯƠNG 2: CƠ SỞ LÝ THUYẾT VÀ PHƯƠNG PHÁP NGHIÊN CỨU (CÂU HỎI 1 & 3)

2.1 2.1. Quy trình Tiền xử lý Ngôn ngữ Tự nhiên

Xử lý văn bản thô đòi hỏi chuyển đổi chuỗi ký tự không cấu trúc thành biểu diễn ma trận số học thích hợp cho thuật toán học máy. Quy trình tiền xử lý tuân thủ các bước toán học:

2.1.1 2.1.1. Chuẩn hóa Văn bản (Text Normalization)

Mọi chuỗi văn bản x_i được đưa về dạng chữ thường (Lowercasing) và loại bỏ ký tự đặc biệt:

$$x'_i = \text{RegexReplace}(\text{ToLower}(x_i), "[\sim a-zA-Z0-9\s]", "") \quad (2)$$

Thao tác này làm giảm kích thước không gian từ vựng $|\mathcal{V}|$, tránh phân tách các từ đồng dạng như "Good", "GOOD", và "good".

2.1.2 2.1.2. Trích xuất Chuỗi Từ đi kèm (N-gram Extraction)

Biểu diễn N-gram ghép nối k từ liên tiếp để duy trì cấu trúc ngữ cảnh ngắn:

$$\text{N-gram}(x'_i, k) = \{(w_j, w_{j+1}, \dots, w_{j+k-1}) \mid 1 \leq j \leq |x'_i| - k + 1\} \quad (3)$$

Trong thực nghiệm này, chúng tôi cấu hình $k \in \{1, 2\}$ (Unigrams và Bigrams). Việc bổ sung Bigram cho phép mô hình bắt được các cụm phủ định quan trọng như "not working", "stop freezing", "no issues".

2.2 2.2. Biểu diễn Trọng số Văn bản TF-IDF (TfidfVectorizer)

Hàm `TfidfVectorizer` tích hợp hai phép biến đổi toán học nhằm lượng hóa mức độ đóng góp của từng từ t trong văn bản d thuộc tập văn bản D :

2.2.1 2.2.1. Tần suất Từ (Term Frequency - TF)

Đo lường mức độ xuất hiện của từ t trong một bài đánh giá d :

$$\text{TF}(t, d) = \frac{f_{t,d}}{\sum_{t' \in d} f_{t',d}} \quad (4)$$

trong đó $f_{t,d}$ là số lần từ t xuất hiện trực tiếp trong bài đánh giá d .

2.2.2 2.2.2. Tần suất Văn bản Nghịch đảo (Inverse Document Frequency - IDF)

Đánh giá mức độ hiếm của từ t trên toàn bộ tập dữ liệu D :

$$\text{IDF}(t, D) = \log \left(\frac{1 + |D|}{1 + |\{d \in D : t \in d\}|} \right) + 1 \quad (5)$$

Hàm log cùng hằng số làm mượt Smooth +1 ngăn hiện tượng chia cho 0 và thu hẹp biên độ trọng số. Các từ nổi phổ biến (như *"the"*, *"and"*, *"is"*) có $|d \in D : t \in d| \approx |D|$, dẫn đến $IDF \rightarrow 1$. Ngược lại, các từ đặc thù như *"defective"* có IDF rất cao.

2.2.3 2.2.3. Trọng số TF-IDF Tổng hợp

$$TF-IDF(t, d, D) = TF(t, d) \times IDF(t, D) \quad (6)$$

Ma trận kết quả được chuẩn hóa theo chuẩn L_2 Euclidean để triệt tiêu ảnh hưởng của độ dài bài viết:

$$v_d = \frac{\mathbf{v}_{\text{raw}}}{\|\mathbf{v}_{\text{raw}}\|_2} = \frac{\mathbf{v}_{\text{raw}}}{\sqrt{\sum_t TF-IDF(t, d, D)^2}} \quad (7)$$

2.3 2.3. Ngăn ngừa Rò rỉ Dữ liệu (Data Leakage) bằng Scikit-Learn Pipeline

Rò rỉ dữ liệu (Data Leakage) là hiện tượng tri thức từ tập kiểm thử (Test Set) vô tình thẩm thấu vào tập huấn luyện (Train Set), dẫn đến kết quả đánh giá mô hình lạc quan một cách ảo tưởng (Over-optimistic evaluation).

Giai đoạn	Quy trình Sai (Gây Data Leakage)	Quy trình Đúng (Scikit-Learn Pipeline)
1. Tính IDF	Fit <code>TfidfVectorizer</code> trên toàn bộ dữ liệu Train + Test	Chỉ gọi <code>fit_transform</code> trên tập dữ liệu Train
2. Lọc Từ vựng	Từ vựng tập Test được đưa vào Từ điển Từ vựng $ \mathcal{V} $	Từ vựng chỉ được tạo dựa trên tập Train
3. Transform Test	Chiếu Test set lên IDF chứa thông tin tập Test	Chỉ gọi <code>transform</code> trên tập Test bằng tham số của Train
4. Kết quả	Đánh giá sai lệch, suy giảm mạnh khi triển khai	Kết quả trung thực, phản ánh khả năng tổng quát hóa

Hình 1: Đối sánh quy trình xử lý dữ liệu tránh rò rỉ ranh giới giữa Train và Test set

Lớp Pipeline đóng gói quy trình xử lý thành một thực thể thống nhất:

Text Vectorizer (TF-IDF) $\rightarrow$ Class Weighting $\rightarrow$ Classifier Model

Khi kết hợp với Cross-Validation, Pipeline đảm bảo mỗi K -fold đều thực hiện lại quá trình `fit` từ vựng chỉ trên $K - 1$ fold huấn luyện, cách ly hoàn toàn 1 fold validation.

2.4 2.4. Toán học các Thuật toán Phân loại Thử nghiệm

2.4.1 2.4.1. Dummy Classifier (Baseline)

Mô hình quy tắc ngây thơ, luôn dự đoán nhãn c^* có tần suất xuất hiện cao nhất trong tập huấn luyện:

$$\hat{y} = \arg \max_{c \in \{0,1,2\}} \sum_{i=1}^{N_{\text{train}}} \mathbb{I}(y_i = c) \quad (8)$$

Mục đích: Thiết lập ngưỡng hiệu năng tối thiểu (Baseline score).

2.4.2 2.4.2. Multinomial Naive Bayes

Dựa trên định lý Bayes với giả định độc lập điều kiện giữa các từ:

$$P(y = c | \mathbf{x}) \propto P(y = c) \prod_{j=1}^{|\mathcal{V}|} P(x_j | y = c)^{f_j} \quad (9)$$

Xác suất hậu thể được ước lượng với tham số làm mượt Laplace ($\alpha = 1.0$):

$$\hat{P}(x_j | y = c) = \frac{\sum_{i \in \text{Class } c} \text{TF-IDF}(w_j, d_i) + \alpha}{\sum_{j'=1}^{|\mathcal{V}|} \sum_{i \in \text{Class } c} \text{TF-IDF}(w_{j'}, d_i) + \alpha |\mathcal{V}|} \quad (10)$$

2.4.3 2.4.3. Logistic Regression (Điều chỉnh Trọng số Lớp - Balanced)

Logistic Regression tối ưu hóa hàm mất mát Cross-Entropy có chứa trọng số cân bằng lớp W_c :

$$\mathcal{J}(\mathbf{w}, b) = -\frac{1}{N} \sum_{i=1}^N W_{y_i} \sum_{c=0}^2 \mathbb{I}(y_i = c) \log P(y_i = c | \mathbf{x}_i; \mathbf{w}) + \frac{1}{2C} \|\mathbf{w}\|_2^2 \quad (11)$$

Trong đó xác suất Softmax cho lớp c là:

$$P(y = c | \mathbf{x}; \mathbf{w}) = \frac{\exp(\mathbf{w}_c^T \mathbf{x} + b_c)}{\sum_{k=0}^2 \exp(\mathbf{w}_k^T \mathbf{x} + b_k)} \quad (12)$$

Trọng số cân bằng lớp W_c nghịch đảo với tần suất xuất hiện của lớp c :

$$W_c = \frac{N_{\text{samples}}}{N_{\text{classes}} \times N_c} = \frac{N}{3 \times N_c} \quad (13)$$

2.4.4 2.4.4. Linear Support Vector Classifier (LinearSVC Balanced)

LinearSVC tìm siêu phẳng tối ưu phân tách các lớp bằng cách tối ưu hóa hàm mất mát Hinge Loss mở rộng cho đa lớp:

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|_2^2 + C \sum_{i=1}^N W_{y_i} \max \left(0, 1 - (\mathbf{w}_{y_i}^T \mathbf{x}_i - \max_{j \neq y_i} \mathbf{w}_j^T \mathbf{x}_i) \right) \quad (14)$$

2.5 2.5. Báo cáo Đánh giá Mô hình (Classification Report Metrics)

Hiệu năng mô hình được đo lường qua các chỉ số trong báo cáo phân loại:

$$\text{Precision}_c = \frac{TP_c}{TP_c + FP_c} \quad (15)$$

$$\text{Recall}_c = \frac{TP_c}{TP_c + FN_c} \quad (16)$$

$$\text{F1-score}_c = 2 \times \frac{\text{Precision}_c \times \text{Recall}_c}{\text{Precision}_c + \text{Recall}_c} \quad (17)$$

$$\text{Macro Average F1} = \frac{1}{3} \sum_{c=0}^2 \text{F1-score}_c \quad (18)$$

$$\text{Weighted Average F1} = \sum_{c=0}^2 \left(\frac{N_c}{N_{\text{total}}} \times \text{F1-score}_c \right) \quad (19)$$

Ý nghĩa cốt lõi đối với bài toán mất cân bằng nhãn: Chỉ số **Accuracy** (Độ chính xác tổng thể) bị chi phối hoàn toàn bởi lớp đa số (Tích cực chiếm 90.55%). Một mô hình luôn dự đoán lớp Tích cực sẽ có Accuracy đạt 90.55%, nhưng chỉ số **Macro Average F1** sẽ rơi xuống mức cực thấp (0.317). Do đó, **Macro F1-score** là thước đo chuẩn xác nhất để đánh giá toàn diện hiệu năng mô hình trên cả 3 lớp cảm xúc.

3. CHƯƠNG 3: THỰC NGHIỆM KHÁM PHÁ VÀ TIỀN XỬ LÝ DỮ LIỆU (CÂU HỎI 2)

3.1 3.1. Quy trình Làm sạch và Chuẩn hóa Dữ liệu

Tập dữ liệu gốc bao gồm **4,915 bản ghi đánh giá Amazon** với 12 trường thông tin (bao gồm reviewText, overall, summary, helpful, reviewTime). Quy trình kiểm định chất lượng dữ liệu thực hiện theo các bước:

1. **Xử lý giá trị khuyết (Missing Value Imputation):** Kiểm tra phát hiện 1 dòng dữ liệu bị khuyết trường nội dung văn bản reviewText (chỉ có điểm sao overall). Dòng này lập tức bị loại bỏ do không chứa tín hiệu ngôn ngữ.
2. **Loại bỏ bản ghi trùng lặp (Deduplication):** Tiến hành so sánh trùng lặp đa trường (reviewerID, asin, reviewText). Phát hiện 2 bài đánh giá bị gửi trùng lặp nhiều lần.
3. **Tập dữ liệu sạch cuối cùng:** Đạt **4,912 bản ghi hợp lệ** đưa vào huấn luyện và kiểm thử.

3.2 3.2. Phân tích Hiện tượng Mất Cân Bằng Nhãn (Class Imbalance)

Nhãn cảm xúc mục tiêu được gán dựa trên khung điểm sao overall:

- **Label 0 (Tiêu cực):** overall $\in \{1.0, 2.0\}$.
- **Label 1 (Trung tính):** overall = 3.0.
- **Label 2 (Tích cực):** overall $\in \{4.0, 5.0\}$.

Bảng 1: Thống kê mô tả chi tiết phân bố nhãn cảm xúc trong bộ dữ liệu Amazon

Nhãn cảm xúc	Thang điểm sao	Số lượng mẫu	Tỷ lệ (%)	Tỷ lệ lệch nhãn	Trọng số W_c
Tiêu cực (Label 0)	1.0 – 2.0 sao	324	6.60%	1 : 13.7	5.053
Trung tính (Label 1)	3.0 sao	140	2.85%	1 : 31.8	11.695
Tích cực (Label 2)	4.0 – 5.0 sao	4,448	90.55%	31.8 : 1	0.368
Tổng cộng	–	4,912	100.00%	–	–

Nhận xét nghiệp vụ về sự lệch nhãn: Tỷ lệ lệch nhãn giữa lớp Tích cực và Trung tính đạt mức **31.8 : 1**. Sự áp đảo này phản ánh tâm lý thực tế của người dùng thương mại điện tử Amazon: khách hàng chỉ dành thời gian viết đánh giá khi họ cực kỳ hài lòng với sản phẩm, hoặc khi sản phẩm gặp sự cố nghiêm trọng khiến họ tức giận. Nhóm đánh giá trung tính (3 sao) chiếm tỷ lệ rất thấp do tâm lý do dự ít kích hoạt hành vi viết đánh giá dài.

3.3 3.3. Phân tích Cấu trúc Độ dài Văn bản (Word Count Analysis)

Tính toán số lượng từ trong nội dung bài viết (word_count) mang lại những phát hiện quan trọng về đặc trưng hành vi ngôn ngữ:

Các phát hiện thống kê sâu:

Bảng 2: Chỉ số thống kê mô tả cấu trúc độ dài văn bản (Word Count) theo từng lớp nhãn

Lớp cảm xúc	Trung bình	Độ lệch chuẩn	Trung vị	Q1 (25%)	Q3 (75%)	IQR	Tối đa
Tiêu cực (Label 0)	106.5 từ	138.2 từ	78 từ	38 từ	132 từ	94 từ	1,554 từ
Trung tính (Label 1)	73.3 từ	82.4 từ	50 từ	26 từ	88 từ	62 từ	612 từ
Tích cực (Label 2)	45.6 từ	54.1 từ	31 từ	18 từ	54 từ	36 từ	1,028 từ
Toàn bộ dữ liệu	50.5 từ	65.8 từ	34 từ	19 từ	59 từ	40 từ	1,554 từ

- 1. Phân phối độ lệch phải nghiêm trọng (Skewness = 8.48, Kurtosis = 112.4):** Đa số đánh giá tập trung ở quy mô ngắn (< 50 từ), nhưng phân phối có đuôi rất dài với một số bài viết vượt 1,000 từ.
- 2. Tương quan nghịch giữa Độ dài và Mức độ HÀi lòng:** Bài đánh giá Tiêu cực có độ dài trung bình ****106.5 từ****, gấp ****2.34 lần**** so với bài đánh giá Tích cực (45.6 từ). Người dùng gặp sự cố (thẻ nhớ hỏng, mất dữ liệu, hàng lỗi) cảm thấy cần phải giải thích chi tiết quá trình diễn ra lỗi, chứng minh họ đã thao tác đúng nhằm đòi hoàn tiền hoặc cảnh báo cộng đồng.

3.4 Trích xuất Đặc trưng Từ vựng Phân biệt (Top TF-IDF Keywords/Bigrams)

Bảng 3: Danh sách các đặc trưng từ vựng và cụm từ đi kèm có trọng số TF-IDF cao nhất

Nhãn cảm xúc	Các từ vựng / N-grams định hình ngữ nghĩa (Top TF-IDF Features)
Tiêu cực (Label 0)	<i>corrupt, failed, waste, return, defective, stop working, lost data, refund, junk, useless, unreliable, worst, error, freeze, died, trash, slow read, card failed</i>
Trung tính (Label 1)	<i>okay, fine, average, cheap, expected, slow but, higher capacity, decent, not bad, works fine, ordinary, acceptable, fair, price okay, speed average</i>
Tích cực (Label 2)	<i>great, works, fast, perfect, recommend, good price, love, no issues, phone memory, excellent, highly recommend, awesome, speed, flawless, expansion</i>

4. CHƯƠNG 4: QUY TRÌNH THỰC NGHIỆM VÀ CẤU HÌNH MÔ HÌNH (CÂU HỎI 3)

4.1 4.1. Kiến trúc Pipeline và Phân tách Dữ liệu

Để đảm bảo tính trung thực thực nghiệm, dữ liệu được phân tách theo chiến lược ****Stratified Train/Test Split****:

- ****Tập huấn luyện (Train set):**** 85% dữ liệu (****4,175 mẫu****), bảo toàn chính xác tỷ lệ nhãn gốc 31.8 : 1.
- ****Tập kiểm thử độc lập (Test set):**** 15% dữ liệu (****737 mẫu****), hoàn toàn được cách ly tuyệt đối trong suốt quá trình xây dựng từ điển TF-IDF và huấn luyện mô hình.

4.2 4.2. Cấu hình Tham số Chi tiết cho các Mô hình Thực nghiệm

Bảng 4: Ma trận cấu hình kỹ thuật và siêu tham số cho 5 mô hình phân loại

Mô hình thử nghiệm	Thành phần Vectorizer	Cấu hình Hyperparameters thuật toán
1. Dummy Classifier	None	strategy='most_frequent'
2. MultinomialNB	TfidfVectorizer(ngram=(1,2))	alpha=1.0, fit_prior=True
3. Logistic Regression (Default)	TfidfVectorizer(max_features=5000)	class_weight=None, solver='lbfgs'
4. LinearSVC (Balanced)	TfidfVectorizer(ngram=(1,2))	C=1.0, class_weight='balanced', loss='squared_hinge'
5. Logistic Regression (Tuned)	TfidfVectorizer(max_features=5000, min_df=2, ngram=(1,2))	C=3.0, class_weight='balanced', solver='lbfgs', max_iter=1000

5. CHƯƠNG 5: KẾT QUẢ THỰC NGHIỆM VÀ PHÂN TÍCH ĐÁNH GIÁ

5.1 5.1. So sánh Hiệu năng Tổng hợp trên Tập Kiểm thử Nội bộ (737 mẫu)

Bảng 5: Bảng đối sánh hiệu năng chi tiết giữa các mô hình phân loại trên tập Test độc lập

Mô hình thử nghiệm	Accuracy	Macro F1	Recall (Lớp 0)	Recall (Lớp 1)	ROC-AUC
1. Dummy Classifier	0.905	0.317	0.000	0.000	0.500
2. Multinomial Naive Bayes	0.910	0.380	0.042	0.000	0.762
3. Logistic Regression (Default)	0.923	0.458	0.271	0.000	0.841
4. LinearSVC (Balanced)	0.912	0.575	0.729	0.182	0.825
5. Logistic Regression (Tuned)	0.919	0.593	0.771	0.182	0.884

Phân tích kết quả thực nghiệm:

- Các mô hình không điều chỉnh trọng số lớp (MultinomialNB và Logistic Regression Default) đạt Accuracy nguy tạo rất cao (~ 91–92%) nhưng thất bại hoàn toàn trong việc phát hiện đánh giá tiêu cực và trung tính (Recall lớp 0 chỉ đạt 4.2% và 27.1%, Recall lớp 1 bằng 0%).
- Tích hợp cơ chế `class_weight='balanced'` giúp mô hình Logistic Regression Tuned bứt phá chỉ số **Recall của lớp Tiêu cực từ 27.1% lên 77.1%**, đồng thời nâng chỉ số **Macro F1 tổng thể từ 0.458 lên 0.593**.

5.2 5.2. Báo cáo Phân loại Chi tiết (Classification Report) Mô hình Tối ưu

Bảng 6: Báo cáo chi tiết hiệu năng từng lớp của mô hình Logistic Regression Tuned

Nhãn cảm xúc	Precision	Recall	F1-Score	Support (Số mẫu)
Tiêu cực (Label 0)	0.514	0.771	0.617	48 mẫu
Trung tính (Label 1)	0.222	0.182	0.200	22 mẫu
Tích cực (Label 2)	0.984	0.954	0.968	667 mẫu
Accuracy tổng thể	–	–	0.919	737 mẫu
Macro Average	0.573	0.635	0.593	737 mẫu
Weighted Average	0.930	0.919	0.923	737 mẫu

5.3 5.3. Phân tích Ma trận Nhầm lẫn và Các Trường hợp Sai số

Bảng 7: Ma trận nhầm lẫn (Confusion Matrix) mô hình Logistic Regression Tuned

Thực tế (Actual)	Dự đoán của Mô hình (Predicted)			Tổng mẫu
	Tiêu cực (0)	Trung tính (1)	Tích cực (2)	
Tiêu cực (0)	37	3	8	48
Trung tính (1)	3	4	15	22
Tích cực (2)	32	11	624	667
Tổng dự đoán	72	18	647	737

Phân tích định tính các trường hợp dự đoán sai (Qualitative Error Analysis):

1. **Lỗi Mỉa mai và Cấu trúc Câu Phức hợp (8 mẫu Tiêu cực bị nhầm sang Tích cực):** Ví dụ: "Great card if you love losing your photos after two days of use!" → Từ vựng TF-IDF nhận diện mạnh từ "Great" và "love", trong khi cụm từ chỉ hỏng hóc "losing your photos" có trọng số bị pha loãng, dẫn đến mô hình dự đoán nhầm thành Tích cực.
2. **Thách thức Nhận diện Lớp Trung tính (15 mẫu Trung tính bị nhầm sang Tích cực):** Ví dụ: "The speed is average, not super fast but price was cheap enough." → Văn bản chứa cả từ tích cực ("cheap") lẫn từ tiêu cực nhẹ ("not super fast"). Biểu diễn TF-IDF dạng Bag-of-Words bị triệt tiêu trọng số lẫn nhau, khiến mô hình nghiêng về nhãn Tích cực do tần suất ưu thế của nhãn này.

5.4. Thực nghiệm Kiểm thử trên Tập Dữ liệu Mở rộng (External Test Set)

Để đánh giá khả năng tổng quát hóa trên các ngành hàng sản phẩm khác, chúng tôi kiểm thử mô hình trên tập dữ liệu mới (`external_test.jsonl` gồm **5,000 mẫu đánh giá Amazon mở rộng**).

Bảng 8: So sánh đối sánh hiệu năng giữa tập Test nội bộ và tập Test ngoài (External Test)

Chỉ số đánh giá	Tập Test Nội bộ (737 mẫu)	Tập Test Mở rộng (5,000 mẫu)
Accuracy	91.9%	86.4%
Macro F1-score	0.593	0.389
Recall (Tiêu cực - Label 0)	77.1%	41.2%
Recall (Trung tính - Label 1)	18.2%	8.5%
Recall (Tích cực - Label 2)	95.4%	91.8%

5.5. Phân tích Nguyên nhân Suy giảm Hiệu năng (Domain Shift Analysis)


Chỉ số Macro F1 sụt giảm mạnh từ **0.593 xuống 0.389** khi đánh giá trên tập ngoài. Nguyên nhân kỹ thuật do:

1. **Sự Dịch chuyển Miền Từ vựng (Domain Shift):** Tập huấn luyện ban đầu tập trung vào linh kiện điện tử / thẻ nhớ (từ khóa: *format, SD, read/write, phone memory*). Tập mở rộng bao gồm quần áo, sách, đồ gia dụng (từ khóa: *fabric, fitting, size, soft, page quality*). Các từ khóa tiêu cực thuộc ngành hàng mới trở thành từ chưa từng thấy (Out-Of-Vocabulary - OOV) đối với từ điển TF-IDF đã fit.
2. **Hạn chế của Phương pháp Trực giao Bag-of-Words:** TF-IDF biểu diễn mỗi từ là một chiều không gian độc lập trực giao. Mô hình không thể học được tính tương đồng ngữ nghĩa (Semantic Similarity) giữa từ "corrupt" (thẻ nhớ) và "damaged" (đồ gia dụng).

6. CHƯƠNG 6: ĐỀ XUẤT KIẾN TRÚC VÀ NÂNG CẤP HỆ THỐNG

6.1 6.1. Ứng dụng Mô hình Ngôn ngữ Pre-trained Transformers (RoBERTa / DeBERTa)

Để khắc phục hạn chế của TF-IDF và hiện tượng Domain Shift, kiến trúc hệ thống thực tế nên được nâng cấp sang mô hình Transformer:



Hình 2: Sơ đồ kiến trúc đề xuất nâng cấp hệ thống dựa trên Transformer

Ưu điểm vượt trội của Transformer:

- ****Học Ngữ cảnh Hai chiều (Bidirectional Context):**** Giải quyết triệt để lỗi mỉa mai (Sarcasm) bằng cách phân tích sự kết hợp giữa các từ khen ngợi và từ gây lỗi trong toàn bộ câu.
- ****Khả năng Tổng quát hóa Đa miền (Cross-domain Generalization):**** Nhờ được tiền huấn luyện trên hàng trăm tỷ từ, mô hình hiểu ngữ nghĩa chung của từ tiêu cực bất kể ngành hàng sản phẩm.

6.2 6.2. Kỹ thuật Tái lấy mẫu và Loss Function Nâng cao

1. **Tái lấy mẫu Phức hợp SMOTE-NC:** Sinh các mẫu giả lập (Synthetic Samples) chất lượng cao cho lớp Trung tính (3 sao) dựa trên khoảng cách Nearest Neighbors trong không gian đặc trưng.
2. **Ứng dụng Focal Loss:** Thay thế Cross-Entropy truyền thống bằng Focal Loss nhằm tập trung tối ưu hóa các mẫu khó phân loại (Hard Examples):

$$\mathcal{L}_{\text{Focal}} = -\alpha_c(1 - p_t)^\gamma \log(p_t) \quad (20)$$

với $\gamma = 2.0$ giúp giảm thiểu ảnh hưởng của các mẫu Tích cực dễ phân loại.

7. CHƯƠNG 7: KẾT LUẬN

Bài báo cáo đã hoàn thành toàn bộ các mục tiêu nghiên cứu đặt ra:

1. Thực hiện quy trình EDA và tiền xử lý chuẩn hóa thành công tập dữ liệu 4,912 bản ghi đánh giá sản phẩm Amazon.
2. Biểu diễn chi tiết toán học của bộ lọc TF-IDF và cơ chế đóng gói Pipeline chống rò rỉ dữ liệu.
3. Chứng minh thực nghiệm vai trò quyết định của tham số trọng số nhãn `class_weight='balanced'` trong việc nâng Recall lớp Tiêu cực từ 27.1% lên **77.1%** và đẩy chỉ số **Macro F1** đạt **0.593**.
4. Chỉ ra ranh giới hạn chế của phương pháp biểu diễn từ tần suất truyền thống khi đối mặt với hiện tượng Dịch chuyển Miền (Domain Shift) trên tập dữ liệu mở rộng 5,000 mẫu.

TÀI LIỆU THAM KHẢO

- [1] Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.
- [2] Jurafsky, D., & Martin, J. H. (2023). *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition* (3rd ed. draft). Stanford University.
- [3] McAuley, J., & Leskovec, J. (2013). Hidden factors and hidden topics: understanding rating dimensions with review text. *Proceedings of the 7th ACM conference on Recommender systems*, 165-172.
- [4] Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. *NAACL-HLT 2019*.
- [5] Lin, T. Y., Goyal, P., Girshick, R., He, K., & Dollár, P. (2017). Focal loss for dense object detection. *Proceedings of the IEEE international conference on computer vision*, 2980-2988.